



Home

Cover Page

CSIRO Biomass

team : 除草大師2.0



kaggle



Group 7 B1240200008 李怡君
B124020014 查欣瑜



Home

Contents

Page 1

contents



研究背景與動機



研究問題



資料介紹與前處理



方法與模型架構



實驗設計



實驗結果



結論



研究背景與動機

Page 2




- 牧草生物量 (Biomass) 是畜牧業重要指標，用於調控放牧量與牧場資源管理
- 傳統生物量估算仰賴人工取樣，成本高、效率低、誤差大
- 影像結合 AI 的自動化生物量預測成為新趨勢
- Kaggle CSIRO Image2Biomass Challenge 提供多地點、多季節的真實牧草影像
- 本研究希望建立能準確預測生物量的影像回歸模型，並理解 AI 在農業領域的應用挑戰



研究問題

- 基線模型（ResNet18、EfficientNet-B0）在此任務上的表現為何？
- 能否設計一個「弱監督」注意力機制，使模型更聚焦牧草？
- Multi-Task Learning 是否能提供額外資訊，提升穩定性？
- 哪種組合最能在雜訊影像中取得最佳預測？





資料介紹與前處理

介紹

- 資料來源：Kaggle – CSIRO Image2Biomass Challenge
- 資料型態：
 - 牧草原始影像 (RGB)
 - 對應地面量測生物量 (biomass，連續值)
 - 影像分佈來自不同時間、季節與場域
- 資料特性：
 - 光線差異明顯 (晴天、陰天、逆光)
 - 牧草密度差 (稀疏～濃密)
 - 背景雜訊多 (影子、土壤、石頭)
- 評估指標：RMSE (官方指定)



資料介紹與前處理

處理

- 影像標準化與 Resize
 - 統一為 224–256 px，符合 CNN 輸入格式
- 基礎資料增強 (Data Augmentation)
 - 水平／垂直翻轉
 - 亮度、對比度調整
 - 輕微旋轉、裁切 → 提升模型對光照與角度變化的穩健性
- 生物量標籤處理
 - 去除缺失值或異常值
 - 對 label 分佈進行初步分析 (偏度、峰度、極端值)
- 資料切分
 - 訓練集／驗證集 8:2
 - 確保不同季節／地點的案例都有包含



Home

Introduction

Page 6

方法概述

PastureMask-MTLNet

baseline

Soft Mask Attention (SMA)

Multi-Task Learning (MTL)





Home

Baseline

Page 7

baseline


Resnet18

efficientNet-B0



baseline(Resnet18)

- 選擇原因：參數量小、訓練速度快、baseline 常用
- 特色：Residual Block × Skip Connection
- 優點：可減緩梯度消失問題，使深層網路更好訓練





baseline(EfficientNet-B0)

- 選擇原因：效能與效率兼具、參數量更低、影像任務表現優秀
- 特色：MBConv Block × Compound Scaling × Depthwise Convolution
- 優點：高效、高準確度、輕量化且能捕捉細紋理特徵



Soft Mask Attention (SMA)

1. 運作機制 (Mechanism)

- 弱監督學習 (Weakly Supervised) :
 - Ground Truth : Pseudo Mask (自動生成，免人工標註)
 - Loss Function : BCE Loss (強制學習牧草分佈)

2. 特徵優化 (Feature Refinement)

- 運算邏輯 :
- 核心效果 : 抑制背景雜訊 (Suppress Background)
 - 保留牧草特徵 (1)
 - 過濾土壤/陰影 (0)




Soft Mask Attention (SMA)

模組優勢 (Key Advantages)


- Annotation-free：免人工標註
- Auto-Focus：自動聚焦草叢
- Explainable AI：具備高度可解釋性



Original



Baseline Grad-CAM



SMA learned attention



Multi-Task Learning (MTL)

1. 架構設計

- Shared Backbone：提取通用影像特徵。
- Dual Heads：同時預測兩個相關目標。
 - Main Task: Biomass (生物量)
 - Aux Task: Cover Ratio (覆蓋率)

2. 設計邏輯

- 輔助特徵學習：利用覆蓋率提供空間結構資訊 (Spatial Context)。
- 物理意義關聯：生物量 $\approx$ 覆蓋面積 $\times$ 密度。
 - 期望模型透過學習「面積」，提升對「總量」的判斷力。

3. 挑戰與限制

- Task Interference (任務競爭)：不同任務的梯度更新方向不一致，導致特徵衝突 (Feature Conflict)，影響最終預測精度。



Home

Page 13

PastureMask-MTLNet



實驗設計

1. 多目標損失函數 (Multi-Objective Loss Function)

- 針對不同模組特性，設計複合損失函數：

- $L_{total} = \lambda_1 L_{Biomass} + \lambda_2 L_{Mask} + \lambda_3 L_{Cover}$

- MSE Loss：確保生物量 (Biomass) 回歸精準度。

- BCE Loss：強制 Attention Mask 學習正確區域 (草 vs 背景)。

2. 評估與監控機制 (Evaluation & Monitoring)

- 主要指標 (Metrics)：

- RMSE (均方根誤差)：評估預測數值的準確性。

- R^2 Score：評估模型對資料趨勢的解釋力。



實驗設計

3. 實驗架構：消融研究 (Ablation Study)

- 設計四組對照實驗，逐步驗證模組貢獻：
 - Baseline：純 CNN (ResNet18)，作為效能基準
 - SMA：加入 Soft Mask，驗證背景抑制效果
 - MTL：加入 Cover Ratio，驗證結構特徵輔助效果
 - Final：整合 SMA + MTL，評估整體綜效

Model	Backbone	Soft Mask	Multi-Task
Baseline	✓		
SMA	✓	✓	
MTL	✓		✓
Final	✓	✓	✓



實驗結果(消融實驗)

Backbone	Experiment Group	RMSE (↓)	R ² Score (↑)	效能提升 (vs. Baseline)
ResNet	1. Baseline	22.84	0.225	-
	2. + Soft Mask	22.28	0.263	2.45%
	3. + MTL	23.23	0.199	-1.71%
	4.PastureMask-MTLNet	22.72	0.233	0.53%




實驗結果(消融實驗)

Backbone	Experiment Group	RMSE (↓)	R ² Score (↑)	效能提升 (vs. Baseline)
EfficientNet-B0	1. Baseline	13.35	0.451	-
	2. + Soft Mask	14.22	0.338	-6.56%
	3. + MTL	12.74	0.484	4.57%
	4. PastureMask-MTLNet	13.46	0.424	-0.81%




實驗結果(Resnet18趨勢圖)





實驗結果(EfficientNet-B0趨勢圖)






實驗結果(可視化結果)

Baseline(Resnet18)

SMA

MTL

PastureMask-MTLNet






實驗結果(可視化結果)

Target 4 | True: 27.51 | Pred: 30.00


Original




Grad-CAM Heatmap




Overlay




Original




Learned Soft Mask



Grad-CAM



CAM Overlay





實驗結果(參數量分析)

Backbone	Model Stage	Parameters (M)	增長率 (Increase %)
ResNet	Baseline	11.18	0%
	+ Soft Mask	11.72	4.83%
	+ MTL	11.21	0.27%
	PastureMask-MTLNet	11.72	+4.83%< 5% (極低增長)



實驗結果(參數量分析)

Backbone	Model Stage	Parameters (M)	增長率 (Increase %)
EfficientNet-B0	Baseline	4.34	0.00%
	+ Soft Mask	4.44	2.36%
	+ MTL	10.27	136.81%
	PastureMask-MTLNet	10.37	139.17%



結論

1.效能與機制驗證

- 準確度冠軍：EfficientNet + MTL (RMSE 12.74)
 - 強大骨幹 + 結構資訊輔助 → 突破準確度天花板。
- 機制驗證：SMA
 - 視覺化證實能有效抑制背景雜訊，解決傳統CNN 注意力發散問題。



結論

2.效率與輕量化 (Efficiency)

- 絕對輕量：EfficientNet 即使擴充後 (10.3M)，參數量仍小於 ResNet18 Baseline (11.2M)。
- 高性價比：SMA 模組僅增 0.5M 參數，卻顯著提升 ResNet 抗噪能力。



結論

3.最終策略建議

- 競賽導向 (High Performance) → EfficientNet-B0 + MTL
- 實際應用 (Practical & Explainable) → ResNet18 + SMA
 - 理由：運算成本低、訓練收斂穩定、具備清晰的可解釋性 (Mask)。

補充實驗：多模態融合

1. 遇到的瓶頸


- 純影像極限：無論如何調整模型架構，準確度皆遭遇效能天花板。
- 原因推測：生物量不僅取決於「外觀」，更受看不見的環境因素影響。

2. 解決策略：多模態融合 (Data Fusion)

- 視覺特徵：牧草紋理、密度、顏色。
- 非視覺特徵：氣候、土壤數值、季節。
- 方法：將影像與結構化數據同時納入訓練。

3. 實驗結論

- 突破物理限制：引入環境參數有效突破了純影像分析的準確度極限。
- 多變數回歸：證實牧草生物量預測本質上是「視覺 + 環境」的複雜回歸問題。





Home

All pass !

Page 28



Thank You

